AO1 Clase 2 – Limpieza, Transformación y Análisis Exploratorio de Datos con LLMs

Yohana Vega

1. Carga de datos

Se construye el dataset de empleados a partir de los datos dados en la consigna.

In [1]:
```
# Librerías para manipulación, análisis y gráficos
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings("ignore")

# Herramientas de preprocesamiento
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder
```

In [2]:
```
# Construcción del DataFrame con los datos del ejercicio
df = pd.DataFrame({
    "ID": [1, 2, 3, 4, 5],
    "Nombre": ["Juan", "Maria", "Pedro", "Ana", "Luis"],
    "Edad": [32, -28, 40, 35, 50],
    "Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Doct
    "Salario": [50000, 60000, None, 55000, 200000],
    "Categoría": ["Junior", "Senior", "Senior", "Junior", "Manager"],
    "Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

df
```

Out[2]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado
0	1	Juan	32	Licenciado	50000.0	Junior	Activo
1	2	Maria	-28	Ingeniero	60000.0	Senior	ACTIVO
2	3	Pedro	40	Doctorado	NaN	Senior	Inactivo
3	4	Ana	35	Licenciado	55000.0	Junior	Activo
4	5	Luis	50	Doctorado	200000.0	Manager	Inactivo

1. Observación inicial del conjunto de datos

En esta etapa se revisa la estructura general del dataset para identificar posibles problemas de calidad, como valores faltantes, datos inconsistentes o registros que necesiten corrección antes del análisis.

In [3]:
```
print("Información general del dataset:")
print(df.info())

print("\nResumen descriptivo:")
print(df.describe(include="all"))
```

```
Información general del dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 7 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   ID               5 non-null      int64
 1   Nombre           5 non-null      object
 2   Edad             5 non-null      int64
 3   Nivel_Educativo  5 non-null      object
 4   Salario          4 non-null      float64
 5   Categoría        5 non-null      object
 6   Estado           5 non-null      object
dtypes: float64(1), int64(2), object(4)
memory usage: 412.0+ bytes
None

Resumen descriptivo:
              ID Nombre      Edad Nivel_Educativo        Salario Categoría  \
count   5.000000      5   5.00000               5       4.000000         5
unique       NaN      5       NaN               3            NaN         3
top          NaN   Juan       NaN      Licenciado            NaN    Junior
freq         NaN      1       NaN               2            NaN         2
mean    3.000000    NaN  25.80000             NaN   91250.000000       NaN
std     1.581139    NaN  30.84153             NaN   72614.851557       NaN
min     1.000000    NaN -28.00000             NaN   50000.000000       NaN
25%     2.000000    NaN  32.00000             NaN   53750.000000       NaN
50%     3.000000    NaN  35.00000             NaN   57500.000000       NaN
75%     4.000000    NaN  40.00000             NaN   95000.000000       NaN
max     5.000000    NaN  50.00000             NaN  200000.000000       NaN

        Estado
count        5
unique       3
top     Activo
freq         2
mean       NaN
std        NaN
min        NaN
25%        NaN
50%        NaN
75%        NaN
max        NaN
```

2. Clasificación de las variables

- *ID:* dato numérico entero. Funciona como identificador y no aporta valor analítico directo.
- *Nombre:* dato categórico nominal. Se utiliza solo como referencia.
- *Edad:* dato numérico. Debe controlarse porque puede contener errores de carga.
- *Nivel_Educativo:* variable categórica ordinal, ya que existe una jerarquía entre niveles.
- *Salario:* variable numérica continua. Puede presentar faltantes y valores extremos.
- *Categoria:* variable categórica ordinal, porque representa niveles jerárquicos dentro del trabajo.
- *Estado:* variable categórica nominal/binaria. Requiere unificación por inconsistencias de escritura.

In [4]:
```python
print("Cantidad de valores faltantes por columna:")
print(df.isnull().sum())

print("\nRegistros con edad inválida:")
print(df[df["Edad"] < 0])

print("\nCantidad de filas duplicadas:")
print(df.duplicated().sum())

print("\nValores encontrados en la columna Estado:")
print(df["Estado"].unique())
```

```
Cantidad de valores faltantes por columna:
ID                 0
Nombre             0
Edad               0
Nivel_Educativo    0
Salario            1
Categoría          0
Estado             0
dtype: int64

Registros con edad inválida:
   ID Nombre  Edad Nivel_Educativo  Salario Categoría  Estado
1   2  Maria   -28       Ingeniero  60000.0    Senior  ACTIVO

Cantidad de filas duplicadas:
0

Valores encontrados en la columna Estado:
['Activo' 'ACTIVO' 'Inactivo']
```

3. Limpieza de datos

A partir del diagnóstico inicial, se detectaron tres problemas principales:

1. Una edad con valor negativo.
2. Un salario faltante.
3. Inconsistencias en la variable categórica *Estado*.

Para resolverlos:

- la edad negativa se corrige usando valor absoluto,
- el salario faltante se reemplaza por la mediana,
- y los valores de la columna Estado se normalizan para que tengan un mismo formato.

In [5]:
```
# Corrección de edades negativas
df["Edad"] = df["Edad"].abs()
df
```

Out[5]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado
0	1	Juan	32	Licenciado	50000.0	Junior	Activo
1	2	Maria	28	Ingeniero	60000.0	Senior	ACTIVO
2	3	Pedro	40	Doctorado	NaN	Senior	Inactivo
3	4	Ana	35	Licenciado	55000.0	Junior	Activo
4	5	Luis	50	Doctorado	200000.0	Manager	Inactivo

In [6]:
```
# Reemplazo del valor faltante en salario por la mediana
df["Salario"] = df["Salario"].fillna(df["Salario"].median())
df
```

Out[6]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado
0	1	Juan	32	Licenciado	50000.0	Junior	Activo
1	2	Maria	28	Ingeniero	60000.0	Senior	ACTIVO
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo
3	4	Ana	35	Licenciado	55000.0	Junior	Activo
4	5	Luis	50	Doctorado	200000.0	Manager	Inactivo

In [7]:
```
# Estandarización de los valores categóricos en Estado
df["Estado"] = df["Estado"].str.capitalize()
print(df["Estado"].unique())
```

```
['Activo' 'Inactivo']
```

4. Detección de valores atípicos en Salario

Para identificar posibles outliers en la variable *Salario*, se utiliza el método del rango intercuartílico (IQR).
Este procedimiento permite detectar valores demasiado alejados del resto de la distribución.

In [8]:
```
Q1 = df["Salario"].quantile(0.25)
Q3 = df["Salario"].quantile(0.75)
IQR = Q3 - Q1

limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

print("Primer cuartil (Q1):", Q1)
print("Tercer cuartil (Q3):", Q3)
print("IQR:", IQR)
print("Límite inferior:", limite_inferior)
print("Límite superior:", limite_superior)

print("\nPosibles outliers:")
print(df[(df["Salario"] < limite_inferior) | (df["Salario"] > limite_superior)])
```

```
Primer cuartil (Q1): 55000.0
Tercer cuartil (Q3): 60000.0
IQR: 5000.0
Límite inferior: 47500.0
Límite superior: 67500.0

Posibles outliers:
   ID Nombre  Edad Nivel_Educativo   Salario Categoría    Estado
4   5   Luis    50       Doctorado  200000.0   Manager  Inactivo
```

In [9]:
```
# Eliminación de valores atípicos en la columna Salario
df = df[(df["Salario"] >= limite_inferior) & (df["Salario"] <= limite_superior)]
df
```

Out[9]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado
0	1	Juan	32	Licenciado	50000.0	Junior	Activo
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo
3	4	Ana	35	Licenciado	55000.0	Junior	Activo

5. Transformación de variables

Una vez realizado el proceso de limpieza, se transforman algunas variables para facilitar su análisis:

- *Nivel_Educativo* se convierte a formato numérico mediante codificación ordinal.
- *Categoria* también se codifica de forma ordinal.
- *Estado* se transforma en una variable binaria.
- *Salario* se normaliza para llevarlo a una escala comparable.
- Se crea una nueva variable llamada *Anios_Hasta_Jubilacion*.

In [10]:
```
encoder_nivel = OrdinalEncoder(categories=[["Licenciado", "Ingeniero", "Doctorado"]
df.loc[:, "Nivel_Cod"] = encoder_nivel.fit_transform(df[["Nivel_Educativo"]])
df
```

Out[10]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0

In [11]:

```
encoder_categoria = OrdinalEncoder(categories=[["Junior", "Senior", "Manager"]])
df.loc[:, "Categoria_Cod"] = encoder_categoria.fit_transform(df[["Categoría"]])
df
```

Out[11]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Categoria_
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

In [12]:

```
df["Estado_Cod"] = df["Estado"].map({"Activo": 1, "Inactivo": 0})

df
```

Out[12]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Categoria_
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

In [13]:

```
scaler = MinMaxScaler()
df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

df
```

Out[13]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Categoria_
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

In [14]:

```
df["Anios_Hasta_Jubilacion"] = 65 - df["Edad"]

df
```

Out[14]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Categoria_
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

6. Dataset luego de la limpieza y transformación

En esta tabla se observa el resultado final del preprocesamiento aplicado al conjunto de datos.

In [15]:
```
df
```

Out[15]:

	ID	Nombre	Edad	Nivel_Educativo	Salario	Categoría	Estado	Nivel_Cod	Categoria_
0	1	Juan	32	Licenciado	50000.0	Junior	Activo	0.0	
1	2	Maria	28	Ingeniero	60000.0	Senior	Activo	1.0	
2	3	Pedro	40	Doctorado	57500.0	Senior	Inactivo	2.0	
3	4	Ana	35	Licenciado	55000.0	Junior	Activo	0.0	

In [16]:
```
print("Estadísticas descriptivas del dataset procesado:")
print(df.describe())
```

```
Estadísticas descriptivas del dataset procesado:
             ID       Edad       Salario  Nivel_Cod  Categoria_Cod  \
count  4.000000   4.000000      4.000000   4.000000        4.00000
mean   2.500000  33.750000  55625.000000   0.750000        0.50000
std    1.290994   5.057997   4269.562819   0.957427        0.57735
min    1.000000  28.000000  50000.000000   0.000000        0.00000
25%    1.750000  31.000000  53750.000000   0.000000        0.00000
50%    2.500000  33.500000  56250.000000   0.500000        0.50000
75%    3.250000  36.250000  58125.000000   1.250000        1.00000
max    4.000000  40.000000  60000.000000   2.000000        1.00000

       Estado_Cod  Salario_Normalizado  Anios_Hasta_Jubilacion
count        4.00             4.000000                4.000000
mean         0.75             0.562500               31.250000
std          0.50             0.426956                5.057997
min          0.00             0.000000               25.000000
25%          0.75             0.375000               28.750000
50%          1.00             0.625000               31.500000
75%          1.00             0.812500               34.000000
max          1.00             1.000000               37.000000
```

In [17]:
```
print("Matriz de correlación:")
print(df[["Edad", "Salario", "Nivel_Cod", "Categoria_Cod", "Estado_Cod", "Anios_Has
```

```
Matriz de correlación:
                           Edad   Salario  Nivel_Cod  Categoria_Cod  \
Edad                   1.000000 -0.067530   0.464620       0.057073
Salario               -0.067530  1.000000   0.662541       0.845154
Nivel_Cod              0.464620  0.662541   1.000000       0.904534
Categoria_Cod          0.057073  0.845154   0.904534       1.000000
Estado_Cod            -0.823778 -0.292770  -0.870388      -0.577350
Anios_Hasta_Jubilacion -1.000000  0.067530  -0.464620      -0.057073

                        Estado_Cod  Anios_Hasta_Jubilacion
Edad                    -0.823778               -1.000000
Salario                 -0.292770                0.067530
Nivel_Cod               -0.870388               -0.464620
Categoria_Cod           -0.577350               -0.057073
Estado_Cod               1.000000                0.823778
Anios_Hasta_Jubilacion   0.823778                1.000000
```

7. Análisis exploratorio de datos (EDA)

En esta etapa se utilizan visualizaciones para comprender mejor la distribución del salario y observar posibles relaciones entre variables numéricas.

In [18]:
```
plt.figure(figsize=(8, 5))
sns.histplot(df["Salario"], bins=5, kde=True)
```

```
plt.title("Distribución de la variable Salario")
plt.xlabel("Salario")
plt.ylabel("Frecuencia")
plt.show()
```

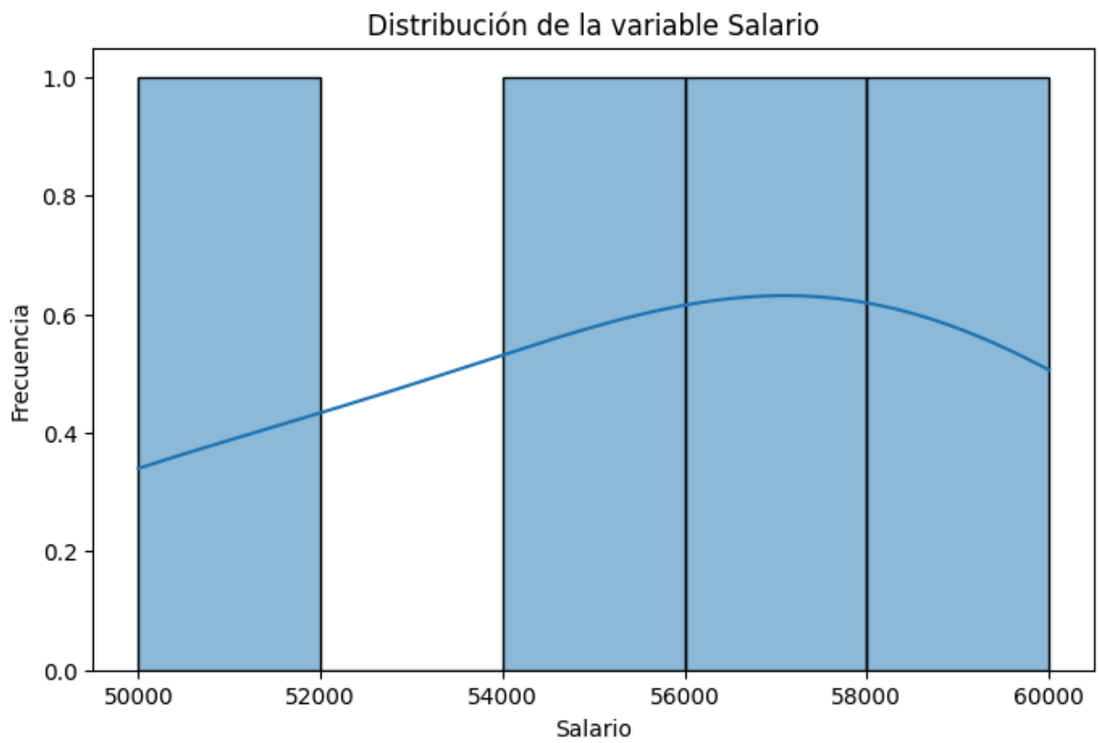

In [19]:
```
plt.figure(figsize=(8, 5))
sns.boxplot(x=df["Salario"])
plt.title("Boxplot del salario")
plt.xlabel("Salario")
plt.show()
```

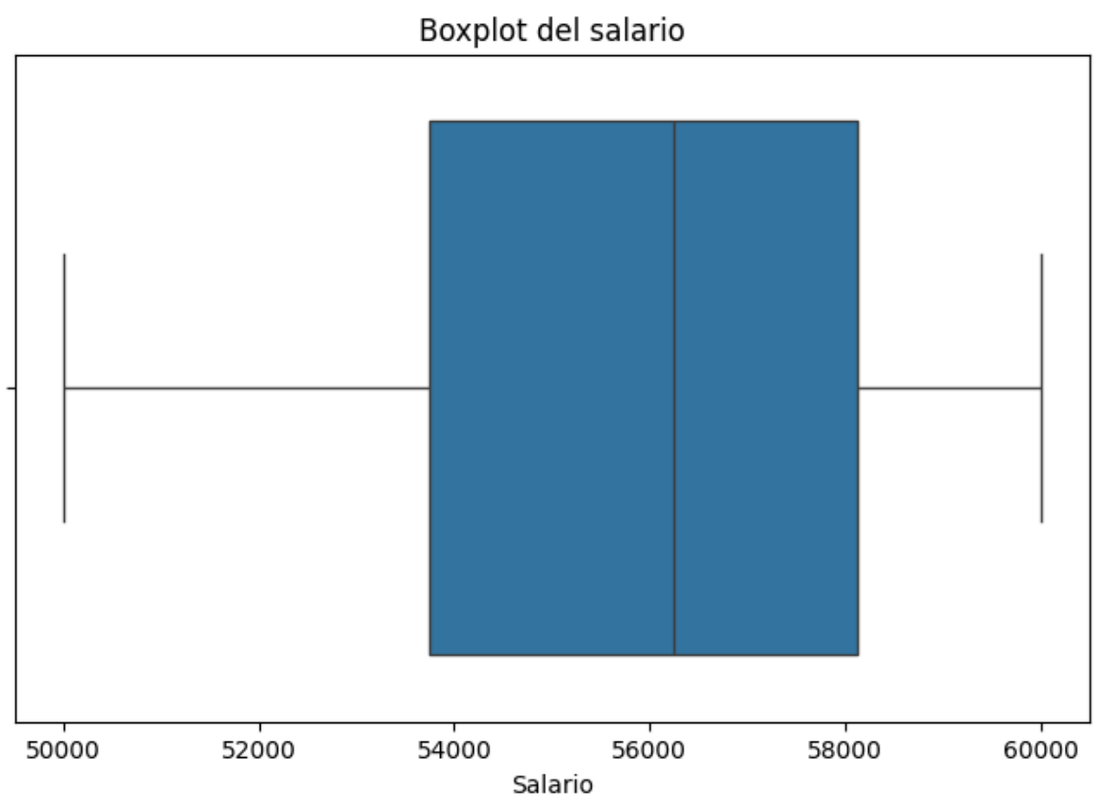

In [20]:
```
plt.figure(figsize=(8, 5))
sns.scatterplot(data=df, x="Edad", y="Salario", hue="Estado")
plt.title("Relación entre edad y salario")
plt.xlabel("Edad")
plt.ylabel("Salario")
plt.show()
```

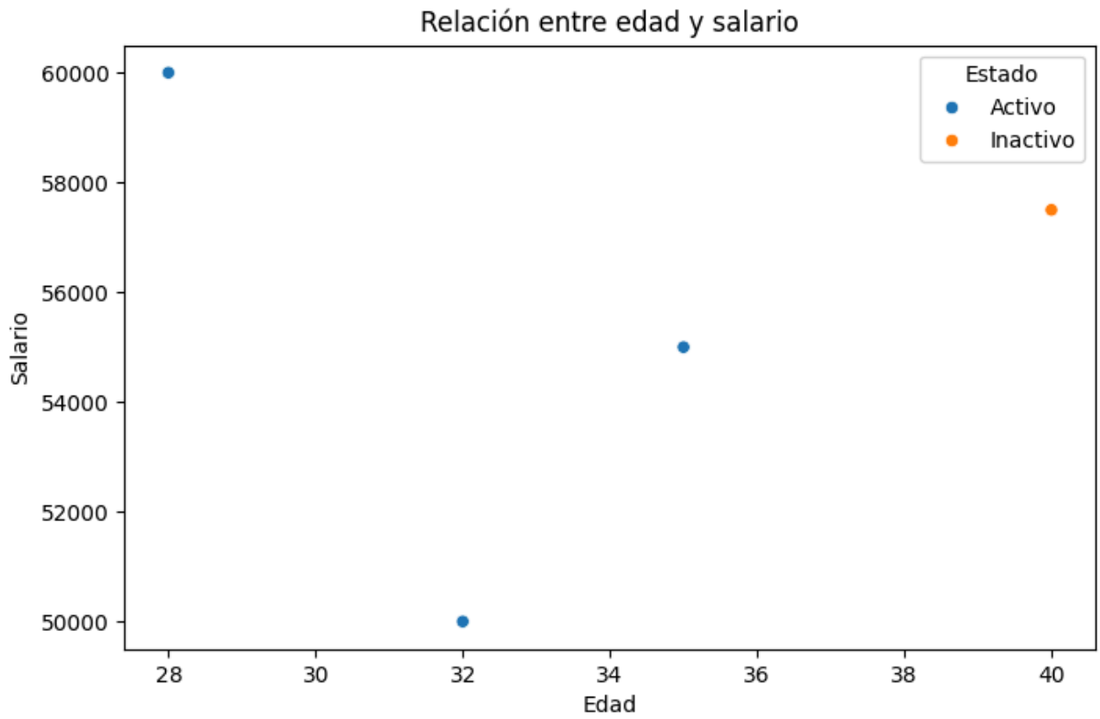

8. Interpretación de resultados

A partir del análisis realizado, se encontraron varios aspectos importantes:

- Se detectó un salario faltante y se reemplazó utilizando la mediana.
- Se corrigió una edad cargada de forma incorrecta.
- Se unificó la escritura de la variable Estado para evitar inconsistencias.
- Se identificó un valor atípico en Salario mediante el método IQR y se decidió eliminarlo.
- Las visualizaciones permiten observar la distribución salarial y analizar cómo se relacionan la edad y el salario dentro del conjunto de datos.

9. Uso de LLM

Prompt 1

"¿Qué método simple puedo usar en Python para detectar valores atípicos en una columna numérica?"

Síntesis de la respuesta

La respuesta sugirió utilizar el método IQR, ya que permite identificar valores extremos a partir de los cuartiles y del rango intercuartílico. También explicó que este criterio es útil cuando se quiere limpiar un conjunto de datos antes del análisis.

Validación personal

Se eligió ese método porque resulta claro, fácil de aplicar y además coincide con las estrategias vistas en clase para detectar outliers en variables numéricas.

Prompt 2

"¿Qué gráficos son útiles para explorar la relación entre edad y salario en un dataset pequeño?"

Síntesis de la respuesta

El modelo propuso utilizar histogramas para observar la distribución, boxplots para detectar dispersión o valores extremos y gráficos de dispersión para analizar la relación entre dos variables numéricas.

Validación personal

Estas sugerencias fueron aplicadas en el trabajo, ya que permiten obtener una visión general del dataset y facilitan la interpretación previa a cualquier modelo.

10. Conclusión

En esta actividad se aplicaron distintas etapas del preprocesamiento de datos: identificación de variables, limpieza, transformación y análisis exploratorio.

Primero se detectaron errores e inconsistencias en el dataset, luego se corrigieron los valores problemáticos y se transformaron variables categóricas a numéricas. Finalmente, mediante gráficos y estadísticas descriptivas, fue posible interpretar mejor el comportamiento de los datos y su estructura general.

In [ ]:

```

```